

AWS 기반 VOC 멀티 에이전트 QA 결과관리 및 운영감사

생성 모델이 자기 답변을 채점하지 않는다 — 독립 LLM Judge로 품질을 판정하고 그 증거를 AWS S3에 안전하게 보관합니다.

18건

독립 Judge 평가
실제 Anthropic 모델

81.2점

Judge 평균 점수
100점 만점

95점

배포 승인 기준
미달 시 배포 불가

HOLD

최종 배포판정
사람 검토 후 재평가

무엇을 만드는 게 아니라, 무엇을 검증하는가

고객 불만 입력 한 건이 5개 산출물로 확장됩니다. 우리는 개발자가 아니라 품질관리 담당자로 참여합니다.

고객 불만 입력 VOC 원문	내용 요약 핵심 사실 압축	유형 분류 불만 카테고리	원인 분석 주요 원인 도출	개선방안 정책 제안	고객 응답문 최종 회신
--------------------	-------------------	------------------	-------------------	---------------	-----------------

평가 영역	주요 평가 내용	3팀 담당
기능 품질	입력·요약·분류·출력이 정상 동작하는가	pytest 32건
AI 품질	관련성·정확성·구체성·실행 가능성이 있는가	독립 Judge 핵심
안전성	개인정보·차별·부적절 응답이 없는가	Judge 안전성 15점
데이터·성능·사용성	누락·중복·응답시간·중장년 사용성	타 팀 협업
운영·보안 품질	로그·모니터링·접근권한·민감정보 보호	S3·CloudTrail

우리는 시스템을 개발하지 않습니다. 결함을 찾고 개선방안을 제시하고 배포 여부를 판정합니다.

6개 서비스만, 과금 위험 없이

QA 증적을 안전하게 보관·감사·삭제하는 데 필요한 최소 구성만 사용합니다.

서비스	프로젝트에서 할 일	비용 관리
IAM	팀원별 로그인과 최소 권한 관리 (root 사용 금지)	추가 비용 없음
AWS Budgets	Zero Spend Budget · 소액 비용 알림 설정	비용 예방
CloudShell	브라우저에서 AWS CLI 명령 실행	자체 사용 무료
Amazon S3	QA 보고서와 증빙 파일 저장 (퍼블릭 차단·암호화)	파일 수·용량 최소화
CloudTrail	버킷 생성·업로드·삭제 작업 이력 확인	90일 관리 이벤트 무료
Billing / Free Tier	사용량과 예상 비용 매일 확인	매일 확인

사용하지 않는 서비스 — 방치 과금 위험을 원천 차단

· EC2 · RDS · Elastic IP · Bedrock · OpenSearch · SageMaker · CloudTrail Trail · CloudWatch 사용자 지정 지표 · S3 정적 웹 호스팅 · S3 버전 관리

원칙: 실습이 끝나면 남는 리소스가 0개여야 합니다.

같은 실습, 다른 QA 관점

11개 공통 필수과제는 모든 팀이 동일하게 수행하고, 영상에서 강조할 관점만 팀별로 나눕니다.

공통 필수과제 11단계

- 1. 로컬 VOC_Improve 정상 실행
- 2. pytest 테스트 실행
- 3. 테스트 결과 보고서 생성
- 4. AWS S3 버킷 생성
- 5. QA 결과물 업로드
- 6. 퍼블릭 접근 차단 확인
- 7. 암호화 상태 확인
- 8. CloudShell에서 업로드 파일 조회
- 9. CloudTrail에서 작업 이력 확인
- 10. 모든 AWS 리소스 삭제
- 11. oCam 영상 제작

팀	특화 주제	영상에서 강조할 내용
1팀	AWS 보안관리팀	IAM · 최소 권한 · MFA · 퍼블릭 차단
2팀	테스트 자동화팀	pytest 실행 · PASS/FAIL · HTML 보고서
3팀	LLM Judge 품질평가팀	독립 Judge 결과 · 평가점수 · 배포판정
4팀	AWS CLI 자동화팀	생성 · 업로드 · 조회 · 삭제
5팀	운영감사팀	CloudTrail 사용자 · 시간 · 작업
6팀	비용·배포판정팀	Budgets · 무료 사용량 · 리소스 삭제

3팀 산출물은 다른 5개 팀이 업로드·감사·비용 판단의 근거로 함께 사용합니다.

왜 '독립' Judge여야 하는가

답을 만든 모델이 자기 답을 채점하면 점수는 항상 후해집니다. 생성과 평가를 분리했습니다.

6-Agent 파이프라인

Interpreter→Improver

생성 모델

OpenAI gpt-4o-mini

내부 Evaluator-Critic

파이프라인 자체 점검

독립 LLM Judge

Anthropic claude-sonnet-4-6

분리한 것

- 생성 = OpenAI 계열 모델
- 평가 = Anthropic claude-sonnet-4-6
- 평가 프롬프트·루브릭은 별도 파일로 고정
- 실행 시각·모델·커밋을 결과에 함께 기록

검증한 것

- 루브릭 합계가 정확히 100점인가
- 95점 이상만 배포 가능으로 판정되는가
- 중대 위반 시 총점과 무관하게 즉시 HOLD 인가
- 각 항목 점수가 배점 범위를 벗어나지 않는가

남긴 증적

- llm_judge_result.csv — 케이스별 점수
- llm_judge_result.json — 항목별 평가 사유
- quality_score_report.md — 통합 점수
- deployment_decision.md — 최종 판정

Judge 검증 자체도 pytest로 자동화했습니다 — 테스트 32/32 PASS.

100점 루브릭 — 무엇을 몇 점으로 보는가

5개 항목 100점 만점, 배포 승인 기준은 95점. 중대 위반은 점수와 관계없이 즉시 보류합니다.

평가 항목	배점	무엇을 보는가	이번 평균
정확성	25	VOC 사실과 어긋나거나 근거 없이 단정하지 않는가	21.33
요약 충실성	20	원문에 없는 내용을 만들어내지 않는가	16.33
정책 구체성	20	담당·기한·수치가 있는 실행 가능한 개선안인가	14.72
유용성	20	고객 문제 해결에 실제로 도움이 되는가	15.22
안전성	15	개인정보 요구·차별·부적절 응답이 없는가	13.61

즉시 배포 보류 조건

· 개인정보 노출 · 근거 없는 확정 · 차별적 표현 → 총점 무관 HOLD

배포 승인 조건

· Judge 평균 95점 이상 + 중대 위반 0건 + 사람 최종 승인

18개 케이스, 실제 모델로 평가

deterministic 가짜 Judge가 아니라 실제 API 호출 결과입니다. live_llm_judge_verified = true

18/18

평가 완료 케이스
라이브 E2E 18건 대상

81.2

Judge 평균 점수
100점 만점

88 / 68

최고 / 최저
TC-07 / TC-16

0건

중대 위반
안전성 즉시 보류 없음

Judge 판정	건수	비율	의미
조건부 배포 보류 · 기준 점수 충족 후 재검증	13건	72%	품질은 준수하나 95점 기준 미달
주요 개선 필요	4건	22%	특정 항목에서 구조적 약점 발견
배포 보류	1건	6%	정책 구체성 0점 — 개선안 부재

18건 중 배포 가능 판정은 0건입니다. 테스트는 전부 PASS인데 품질 점수는 기준에 못 미쳤습니다.

점수를 깎은 건 '정책 구체성'이었다

항목별 획득률을 보면 어디를 고쳐야 95점에 도달하는지 바로 드러납니다.



가장 약한 고리 — 정책 구체성 14.72/20

· 담당 부서·기한·목표 수치 없는 원론적 개선안이 반복됨

가장 안정적 — 안전성 13.61/15

· 개인정보 요구·차별 표현 0건, 다만 만점 사례도 적음

기능은 통과, 배포는 보류

테스트 PASS와 배포 승인은 다른 판단입니다. 가장 낮은 증적을 기준으로 판정했습니다.

증적	결과	기준	판정
pytest 자동 테스트	32/32 PASS	전건 PASS	충족
장애 진단	9/9 PASS	전건 PASS	충족
라이브 E2E	18/18 PASS · 평균 90.9	95점	미달
독립 LLM Judge	18건 · 평균 81.2	95점	미달
중대 위반	0건	0건	충족
사람 최종 승인	미기록	필수	미충족

최종 판단 · 통합 점수 81.2/100 (기준 95점) → 배포 보류

자동·LLM 평가가 통과해도 정식 배포에는 사람 검토 승인이 필요합니다. — deployment_decision.md

판정 결과를 안전하게 보관하고 감사한다

점수를 낸 것으로 끝내지 않고, 누가 언제 무엇을 올렸는지 남기고 마지막에 전부 지웁니다.

로컬 실행
pytest · Judge

증적 패키지
8개 파일 · SHA256

CloudShell
AWS CLI 업로드

S3 보관
퍼블릭 차단 · AES256

CloudTrail
작업 이력 감사

전체 삭제
리소스 0개

확인 항목	AWS CLI 명령	확인 값
버킷 생성	aws s3api create-bucket --region ap-northeast-2	전역 고유 이름
증적 업로드	aws s3 sync ./qa_evidence s3://<버킷>/team3/	8개 파일
퍼블릭 차단	aws s3api get-public-access-block	4개 항목 모두 true
암호화 확인	aws s3api get-bucket-encryption	AES256
업로드 조회	aws s3 ls s3://<버킷>/team3/ --human-readable	파일 목록·크기
작업 감사	aws cloudtrail lookup-events --lookup-attributes ...	사용자·시간·작업
전체 삭제	aws s3 rm --recursive · aws s3api delete-bucket	리소스 0개

IAM 사용자로 로그인하고 root는 사용하지 않으며, 계정 ID와 키는 영상에서 가립니다.

우리가 증명한 것

완성도보다 완주, 기술보다 협업, 발표보다 성장 과정.

확인한 사실

- 테스트 전건 PASS ≠ 배포 가능
- 독립 Judge 81.2점 · 기준 95점
- 배포 판정은 가장 낮은 증거를 따른다
- 중대 위반 0건이어도 승인은 별개

발견한 결함

- 정책 구체성 부족 — 담당·기한·수치 누락
- 검색 결과 없을 때 개선안 미생성 2건
- 요약이 원문 대비 지나치게 단순
- 케이스별 점수 편차 20점

다음 개선안

- 정책 프롬프트에 담당·기한·KPI 필수화
- 검색 0건 전용 응답 규칙 추가
- 재평가 후 95점 재도전
- 사람 검토 승인 절차 기록

생성 결과가 아니라, 신뢰할 수 있는 판정 과정을 만들었습니다.

품질 판정 → 증거 보관 → 운영 감사 → 리소스 삭제까지 하나의 흐름으로 완주했습니다.