

종합 품질평가 결과 보고서

최종 테스트	초기 테스트	통합 점수	배포 기준
35/35 PASS	33 PASS / 2 FAIL	89.0/100	95.0/100

최종 완료 판정

품질평가 수행 및 기능·결함 회귀는 완료되었습니다. 정의된 35건이 모두 통과했습니다.

운영 배포는 보류합니다. 현재 통합 점수 89.0점이 배포 기준 95.0점에 미달하고 사람 승인 기록도 필요합니다.

평가 기간: 2026-07-14 ~ 2026-07-15 · 보고서 생성: 2026-07-15T15:16:31+09:00

1. 품질평가 목적과 3단계 구조

본 평가는 단순 실행 성공이 아니라 VOC 근거 기반 분석, 내부 다중 Agent 진단, 독립 모델 감사와 배포 판단을 하나의 추적 가능한 QA 체계로 검증합니다.

1단계 · VOC 분석 및 정책 개선안 생성

Interpreter가 질문 의도를 해석하고 Retriever가 근거 VOC를 찾습니다. Summarizer가 핵심 원인과 영향을 요약하며 Improver가 담당·기한·우선순위·검증지표를 갖춘 정책안을 생성합니다.

2단계 · 6개 멀티 에이전트 내부 품질진단

Interpreter, Retriever, Summarizer, Evaluator, Critic, Improver의 단계별 출력과 시간, 오류 전파, 사실성, 안전성과 실행 가능성을 진단합니다. Critic 지적은 필요 시 Refine으로 연결됩니다.

3단계 · 독립 LLM Judge 평가

내부 생성·평가와 분리된 교차 모델이 정확성, 요약 충실성, 정책 구체성, 유용성, 안전성을 독립 채점합니다. Judge는 결과를 수정하지 않고 최종 감사 증적을 생성합니다.

2. 전체 35건 테스트 정량 분석

테스트 결과 추이

초기 결함 2건 수정 후 최종 35건 전면 통과



초기



최종

35건 점검 범위

두 도메인 기능 케이스와 핵심 결함 회귀를 함께 검증

이커머스 VOC

18건

보험 VOC

15건

핵심 결함 재시험

2건

초기에는 33 PASS / 2 FAIL로 성공률 94.3%였습니다. 두 결함의 원인 분석·수정·재시험을 거쳐 최종 35 PASS / 0 FAIL, 성공률 100%로 5.7%p 개선되었습니다.


3. 결함관리 내역

ID	결함	원인	시정 조치	최종
DEF-BRANCH-01	분기 인터페이스 오류	OpenAI-Anthropic 분기에서 공급자별 요청 인수가 혼용되어 Anthropic Messages 호출이 거부됨	공급자별 클라이언트를 분리하고 Anthropic 분기에서 temperature를 제거, model-max_tokens-messages만 전달	PASS / 수정 완료
DEF-429-01	API 429 사용량 제한 장애	라이브 병렬 테스트가 공급자 사용량 한도를 초과했으나 일반 서버 오류로만 표시됨	동시 실행 기본 2:최대 4 제한, SDK 재시도 1회, 429 전용 오류코드와 동시 실행 1건 축소 안내 적용	PASS / 운영 모니터링

결함 상태 변화

분기 인터페이스와 API 429 결함의 수정·재시험 결과

초기



최종



4. 내부 평가와 독립 Judge 역할 구분

역할	위치	판단 범위	결과 사용
Evaluator	내부 1차 평가	요약 후보 점수·승자 선택·근거 정합성	후보 선택 결과를 다음 단계로 전달
Critic	내부 비판·교정	누락·과장·안전 위험·구체성 부족 탐지	필요 시 Refine 재작업 유도
독립 LLM Judge	외부 최종 감사	정확성·충실성·정책 구체성·유용성·안전성	산출물 수정 없이 독립 점수와 배포 증거 생성

Evaluator와 Critic은 파이프라인 내부의 품질 루프이며 산출물 선택·교정에 직접 관여합니다. 독립 Judge는 생성 주체와 분리되어 결과를 수정하지 않고 외부 감사 점수와 배포 근거를 제공합니다.

5. 성공적인 품질평가라고 판단한 근거

- 35개 테스트와 요구사항·결함을 1:1로 추적하고 모두 통과했습니다.
- 기능 정상 경로뿐 아니라 포트·API 키·CSV·타임아웃·빈 결과·429 등 실패 경로를 검증했습니다.
- 생성, 내부 평가, 독립 평가를 분리해 자기평가 편향을 줄였습니다.
- 오프라인 결정적 회귀와 실제 LLM 라이브 검증을 분리해 비용과 재현성을 동시에 관리했습니다.
- TXT·XML·HTML·PDF 및 JSON·CSV 원본 증거를 함께 보존합니다.

6. 7월 14일부터의 개발·개선 과정

07-14 · 중복 파이프라인과 불완전한 환경

구현: 단일 오케스트레이터, 의존성·모델·MCP 경로·Retriever 수정
웹 적용: 단건 분석 화면
검증: 첫 Git 기준점, 기본 테스트

07-14 · 6개 서버를 따로 실행하기 어려움

구현: 멀티프로세스 supervisor와 대안 런처
웹 적용: 서버 상태를 웹 진단에 표시
검증: 6001~6006 준비 확인

07-14 · 결과가 비슷하고 검색 오탐 발생

구현: 질문 관점 전달, 검색 관련도 순위, max_items 축소
웹 적용: 6-Agent 단계별 카드
검증: 질문별 결과 차이 확인

07-14 · 테스트에 기대 결과가 없음

구현: JSONL 18건과 의도·키워드·필수·금지 출력
웹 적용: 배치 PASS/FAIL, JSON·CSV 저장
검증: 품질 스키마·금지 표현 테스트

07-15 · 교수님 요구 6번 점수화

구현: 9개 항목 100점, 배포 등급, 즉시 보류
웹 적용: 항목별 점수표와 근거
검증: 오프라인 18/18, 평균 95.6

07-15 · 교수님 요구 7번 장애 진단

구현: 포트·API 키·CSV·지연·Agent 중단 등 7개 시나리오
웹 적용: 장애 진단 버튼과 보고서
검증: 7/7 PASS

07-15 · 교수님 요구 8번 품질 폴더

구현: Agent·E2E·MCP·Judge 테스트와 보고서 생성
웹 적용: 자동 품질 테스트·보고서 목록
검증: 전용 품질 테스트 27/27

07-15 · 실제 모델 품질 확인 필요

구현: 라이브 E2E, 선택 재시험 통합, Anthropic Judge
웹 적용: 비용 동의, case_id 선택, Judge·배포 판단
검증: 라이브 18/18, 90.6점; Judge 89.0, 중대 위반 0

07-15 · 개인정보·프롬프트 공격 위험

구현: PII 마스킹과 프롬프트 공격 중립화
웹 적용: 안전성 근거와 즉시 보류 표시
검증: 안전성 100점, 보안 테스트 PASS

07-15 · CLI 기능이 브라우저에 없음

구현: 품질 운영 대시보드와 8개 웹 작업
웹 적용: 품질·장애·E2E·통합·Judge·배포·다운로드
검증: 웹 API 및 전체 회귀 PASS

07-15 · 라이브 테스트가 약 9.5분 소요

구현: 동시 실행 기본 2건, 재시도 1회 제한
웹 적용: 배치·E2E 동시 실행 선택
검증: 전체 36 PASS; 오프라인 3/3, 6.59초

07-15 · 모든 개발을 발표자료와 웹으로 관리

구현: 상시 원칙·발표 원장·웹 슬라이드 추가
웹 적용: `/presentation` 발표 모드
검증: 발표 페이지·자료 링크 웹 검증

07-15 · 정상 실행 중인 6개 Agent를 포트 충돌로 오인

구현: 포트 점유와 실제 gRPC 준비 상태를 함께 검사해 전체 정상은 재사용, 일부 점유만 충돌 처리
웹 적용: 품질 운영 화면에 실행 상태·재기동 필요 여부·안내 표시
검증: 중복 실행 종료 코드 0, Agent 6/6, 품질진단 27/27, 전체 회귀 38/38

07-15 · 배포 기준이 90점으로 분산 고정되고 최종 보고서가 평균점수를 기준과 비교하지 않음

구현: 저장형 공통 배포 정책, 기본 95점, E2E·Judge 동시 충족 판정, 실제 Judge 우선 선택
웹 적용: 배포 기준 점수 조회·변경·저장과 현재 배포 결과 카드
검증: 95↔96 저장·복원, 통합 89.0/95 배포 보류, 품질진단 28/28, 전체 회귀 43/43

07-15 · 교육 과정 전체 개발·결함·평가 결과를 제출 가능한 종합 보고서와 실행별 증적으로 보존해야 함

구현: 35건 전용 평가, 분기 인터페이스·API 429 결함 회귀, 실행별 TXT·XML·HTML 및 누적 이력, PDF·HTML·XML·TXT·JSON·그래프·ZIP 종합 보고서 생성
웹 적용: 품질 운영 6번에서 `35건 종합 보고서 생성`, 결과 목록 조회·다운로드
검증: 초기 33/35 → 최종 35/35, 품질진단 30/30, 전체 회귀 45/45, PDF 9쪽과 ZIP 첨부 묶음 검증

07-15 · 12개 고도화 요구를 기본 골격이 아닌 실제 QA 운영 기능으로 완성해야 함

구현: Experiment 저장·기준선 비교·추세·실패 분석·6-Agent Trace·사람 승인·5×3 반복성·RAG 6지표·토큰/비용/P95/429-OWASP 20건·CI 95점 게이트·버전·드리프트 구현
웹 적용: 사이드바형 QA Control Center의 대시보드·테스트 케이스·실행 이력·실험 비교·Trace·보안·승인·보고서·설정·통합
검증: 전체 회귀 67/67, 품질 스위트 30/30, Red Team 20/20, 중요 5건×3회 5/5 안정, HTTP/API·JS·DOM 참조 검증 PASS

7. 잔여 위험과 운영 권고사항

잔여 위험 수준

5점 척도 · 점수가 높을수록 운영 전 우선 조치 필요



잔여 위험	수준	운영 권고
95점 배포 기준 미달	5/5	E2E +4.4점, Judge +6.0점 개선 후 재시험
사람 승인 미기록	5/5	승인자·시각·판단 근거를 전자 승인 이력으로 보존
운영 부하·429	4/5	동시성 1~2 유지, 큐·지수 백오프·사용량 알림 추가
인증·TLS·프록시	4/5	로컬 바인딩 이후 운영 게이트웨이 보안 검증
도메인 확장·드리프트	3/5	보험 라이브 전체와 장기 회귀 추세 비교

8. 다형식 품질 증거와 최종 완료 판정

모든 공식 테스트 실행은 타임스탬프가 붙은 TXT·XML·HTML 증거를 별도로 생성하고 test_execution_history.jsonl에 누적합니다. 종합 보고서는 PDF와 ZIP 첨부 묶음으로 보존합니다.

형식	용도
TXT	사람이 읽는 실행 요약·상세 결과·최종 판정
XML	CI/CD·감사 도구가 읽는 구조화된 35건 증거
HTML	브라우저에서 그래프와 표를 확인하는 시각 보고서
PDF	발표·검토·승인을 위한 고정형 종합 보고서
ZIP	보고서·그래프·원본 결과를 한 번에 전달하는 첨부 묶음

최종 종합 평가

[품질평가 수행 완료 · 기능 및 결함 회귀 PASS · 운영 배포 HOLD]

35/35 테스트는 완료되었으나 E2E 90.6점과 독립 Judge 89.0점 중 낮은 통합 점수 89.0점이 배포 기준 95.0점에 미달합니다. 점수 개선과 사람 승인 기록 후 다시 배포 판단을 생성해야 합니다.